

R과통계분석

(youngsik.park@bsl-lausanne.ch)



R에 의한 통계 분석 실습

- 1. R 시작하기
- 2. R에서 데이터 다루기
- 3. R에서데이터시각화:ggplot2
- 4. 통계분석
 - 1) 회귀 모형
 - 2) 로지스틱 회귀 모형



1장. R에 대한 소개



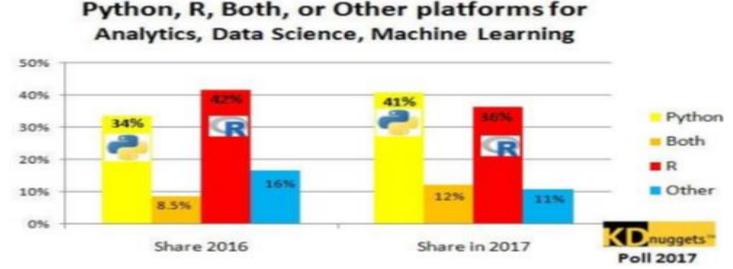
R**의 소개**

- ◎ R은 통계분석과 그래프 작성 등을 위한 프로그래밍 언어이자 개발환경
- ◎ 최초 개발자: Ross Ihaka, Robert Gentleman
- ◎ 오픈 소스 소프트웨어
- ◎ 현재 R Development Core Team에 의해 유지 관리
- ◎ 수많은 R 사용자 그룹에 의한 꾸준한 발전
- ◎ 통계 소프트웨어 중 전세계적으로 가장 많이 사용되는 프로그래밍 언어 中 하나



R**의 현재상황**

- ◎ 차별화된 강점
 - 무료
 - 거의 모든 분야의 통계분석이 가능한 SW
 - 완벽한 그래프 작성 가능
 - 잘 발달된 R커뮤니티를 통한 최첨단 분석기법 활용
- ◎ R의 이러한 장점덕에 파이썬과 함께 언어전쟁에서 생존 中





R**의 단점**

- ◎ 통계분석을 모르는 사용자가 활용하기엔 한계
- ◎ R패키지 내에 존재하는 분석기법을 학습해야 하며, 그 사용법이 무엇인지 알아내야 함
- ◎ R패키지가 과도하게 많이 존재하는 점이 양날의 검!





R VS Python



http://www.bloter.net/archives/252670

What?



Choosing R or Python for Data Analysis? An Infographic

Wondering whether you should use R or Python for your next data analysis post? Check our infographic "Data Science Wars: R vs Python".

I think you'll agree with me if I say:

It's HARD to know whether to use Python or R for data analysis. And this is especially true if you're a newbie data analyst looking for the right language to start with.

It turns out that there are many good resources that can help you to

https://www.datacamp.com/community/tutorials/r-or-python-for-data-analysis



http://the-r.kr/2018/02/15/%EB%8D%B0%EC%9D%B4%ED%84%B0%EA%B3%BC%ED%95%99%EC%9D%84-%EC%9C%84%ED%95%9C-r-vs-python



https://mrchypark.github.io/post/r%EA%B3%BC-python-%EC%A4%91%EC%97%90-%EC%96%B4%EB%96%A4-%EA%B2%83%EC%9D%84-%EA%B3%B5%EB%B6%80%ED%95%B4%EC%95%BC-%ED%95%A0%EA%B9%8C/



R VS Python

	R	python
Purpose	데이터 분석, 통계, 그래픽 모델에 특화 된 언어	범용적인 목적으로 개발된 언어
	Lingua franca of Statistics: R-bloggers	A multi-Purpose Language
Flexibility	모든 종류의 통계 테스트 및 모델을 쉽게 사용하고 읽을 수 있음.	기존에 사용하던 방식이 아닌 새로운 방식에 유연하게 적용 가능 웹 사이트나 애플리케이션을 스크래핑
Ease learning	기초를 익히고나면 쉽게 심화 단계로 나 아갈 수 있음 통계학자에게 편한 툴(Tool)	쉽게 제작할 수 있고 가독성이 뛰어남 초급 프로그래머에게 좋은 언어
장단점	장점 - 통계 분석에 최적화 - 방대한 커뮤니티와 패키지	장점 - 웹 스크랩핑 - 방대한 커뮤니티와 패키지
	단점 - 배우기가 어렵다(너무 많은 패키지) - 속도가 느리다 - 웹 스크랩핑이 어렵다	단점 - R에 비해 패키지가 다양하지 않음 - R보다 분석에 최적화되어 있지 않음
사용자	연구직, 데이터 과학자, 통계 전문가 등	개발 베이스의 데이터 과학자, 프로그래머

https://fmaker7.tistory.com/182



- ◎ R= 'base시스템 (base R)'과 '다양한 패키지(예: tidyverse)'
- ◎ R의 설치는 base 시스템의 설치를 의미
 - 설치 파일: Comprehensive R Archive Network (CRAN)
 - CRAN 사이트: cran.r-project.org





CRAN
Mirrors
what's new?
Task Views
Search

About R R Homepage The R Journal

Software R Sources R Binaries Packages Other

Documentation
Manuals
FAQs
Contributed

The Comprehensive R Archive Network

Download and Install R

Precompiled binary distributions of the base system and contributed packages, **Windows and Mac** users most likely want one of these versions of R:

- Download R for Linux
- Download R for (Mac) OS X
- Download R for Windows

R is part of many Linux distributions, you should check with your Linux package management system in addition to the link above.

Source Code for all Platforms

Windows and Mac users most likely want to download the precompiled binaries listed in the upper box, not the source code. The sources have to be compiled before you can use them. If you do not know what this means, you probably do not want to do it!

- The latest release (2019-03-11, Great Truth) <u>R-3.5.3.tar.gz</u>, read <u>what's new</u> in the latest version.
- Sources of <u>R alpha and beta releases</u> (daily snapshots, created only in time periods before a planned release).
- Daily snapshots of current patched and development versions are available here. Please read about new features and bug fixes before filing corresponding feature requests or bug reports.
- Source code of older versions of R is available here.
- Contributed extension <u>packages</u>

Questions About R

 If you have questions about R like how to download and install the software, or what the license terms are, please read our <u>answers to</u> <u>frequently asked questions</u> before you send an email.

What are B and CRAN?





CRAN Mirrors What's new? Task Views Search

About R R Homepage The R Journal

Software
R Sources
R Binaries
Packages
Other

Documentation
Manuals
FAQs
Contributed

CRAN Mirrors

The Comprehensive R Archive Network is available at the following URLs, please choose a location close to you. Some statistics on the status of the mirrors can be found here: main-page, <a href="windows-windows-network-net

If you want to host a new mirror at your institution, please have a look at the <u>CRAN Mirror</u> HOWTO.

0-Cloud

https://cloud.r-project.org/ Automatic redirection to servers worldwide,

currently sponsored by Rstudio

http://cloud.r-project.org/ Automatic redirection to servers worldwide,

currently sponsored by Rstudio

Algeria

https://cran.usthb.dz/
University of Science and Technology Houari

Boumediene

http://cran.usthb.dz/
University of Science and Technology Houari

Boumediene

Argentina

http://mirror.fcaqlp.unlp.edu.ar/CRAN/ Universidad Nacional de La Plata

Australia

https://cran.csiro.au/ CSIRO http://cran.csiro.au/ CSIRO https://mirror.aarnet.edu.au/pub/CRAN/ AARNET

https://cran.ms.unimelb.edu.au/

University of Melbourne

https://cran.curtin.edu.au/ Curtin University of Technology

Austria

https://cran.wu.ac.at/ Wirtschaftsuniversität Wien





CRAN Mirrors What's new? Task Views Search

About R R Homepage The R Journal

Software R Sources R Binaries Packages Other

Documentation
Manuals
FAQs
Contributed

The Comprehensive R Archive Network

Download and Install R

Precompiled binary distributions of the base system and contributed packages, **Windows and Mac** users most likely want one of these versions of R:

- Download R for Linux
- Download R for (Mac) OS X
- Download R for Windows

R is part of many Linux distributions, you should check with your Linux package management system in addition to the link above.

Source Code for all Platforms

Windows and Mac users most likely want to download the precompiled binaries listed in the upper box, not the source code. The sources have to be compiled before you can use them. If you do not know what this means, you probably do not want to do it!

- The latest release (2019-03-11, Great Truth) R-3.5.3.tar.gz, read what's new in the latest version.
- Sources of <u>R alpha and beta releases</u> (daily snapshots, created only in time periods before a planned release).
- Daily snapshots of current patched and development versions are <u>available here</u>. Please read about <u>new features and bug fixes</u> before filing corresponding feature requests or bug reports.
- Source code of older versions of R is available here.
- Contributed extension packages

Questions About R

 If you have questions about R like how to download and install the software, or what the license terms are, please read our <u>answers to</u> <u>frequently asked questions</u> before you send an email.

What are R and CRAN?





CRAN Mirrors What's new? Task Views

Search

About R R Homepage The R Journal

Software

R Sources

R Binaries

<u>Packages</u>

<u>Other</u>

Documentation

<u>Manuals</u>

FAQs

Contributed

R for Windows

Subdirectories:

Binaries for base distribution. This is what you want to install R for the

first time.

Binaries of contributed CRAN packages (for R >= 2.13.x; managed by Uwe Ligges). There is also information on third party software available

for CRAN Windows services and corresponding environment and make

variables.

old contrib

Binaries of contributed CRAN packages for outdated versions of R (for R

< 2.13.x; managed by Uwe Ligges).

Rtools Tools to build R and R packages. This is what you want to build your

own packages on Windows, or to build R itself.

Please do not submit binaries to CRAN. Package developers might want to contact Uwe Ligges directly in case of questions / suggestions related to Windows binaries.

You may also want to read the R FAQ and R for Windows FAQ.

Note: CRAN does some checks on these binaries for viruses, but cannot give guarantees. Use the normal precautions with downloaded executables.





CRAN Mirrors What's new? Task Views Search

About R R Homepage The R Journal

Software R Sources R Binaries Packages Other

Documentation Manuals FAQs Contributed

R-3.5.3 for Windows (32/64 bit)

Download R 3.5.3 for Windows (79 megabytes, 32/64 bit)

<u>Installation and other instructions</u> New features in this version

If you want to double-check that the package you have downloaded matches the package distributed by CRAN, you can compare the <u>md5sum</u> of the .exe to the <u>fingerprint</u> on the master server. You will need a version of md5sum for windows: both <u>graphical</u> and <u>command line versions</u> are available.

Frequently asked questions

- Does R run under my version of Windows?
- How do I update packages in my previous version of R?
- Should I run 32-bit or 64-bit R?

Please see the <u>R FAQ</u> for general information about R and the <u>R Windows FAQ</u> for Windows-specific information.

Other builds

- Patches to this release are incorporated in the <u>r-patched snapshot build</u>.
- A build of the development version (which will eventually become the next major release of R) is available in the <u>r-devel snapshot build</u>.
- · Previous releases

Note to webmasters: A stable link which will redirect to the current Windows binary release is <a href="mailto: /bin/windows/base/release.htm.

Last change: 2019-03-11

설치 파일 실행



R Studio 의 설치 및 실행

R Studio

- R을 위한 통합 개발 환경
- 무료 오픈소스
- 2011년 최초 출시됨
- 모든 R작업은 R Studio에서 수행되는 것이 바람직

◎ R Studio 설치 방법

- 설치 주소: https://www.rstudio.com/products/rstudio/download/
- 일년에 몇차례 업데이트가 진행됨
- 최근 버전에 RStudio Desktop 1.1.463



R Studio 의 설치 및 실행



Products

Resources

Pricing

About Us

Blogs

Q

RStudio Desktop 1.1.463 — Release Notes

RStudio requires R 3.0.1+. If you don't already have R, download it here.

Linux users may need to import RStudio's public code-signing key prior to installation, depending on the operating system's security policy.

Installers for Supported Platforms

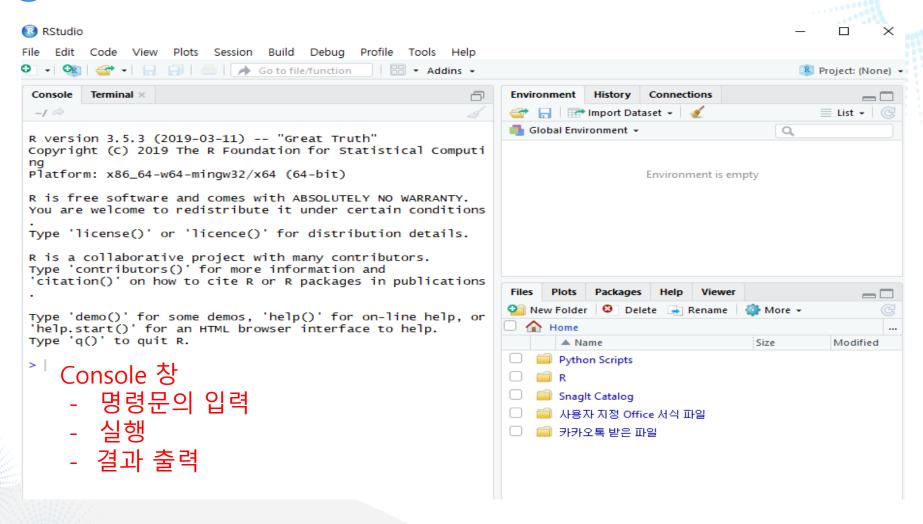
Installers	Size	Date	MD5
RStudio 1.1.463 - Windows Vista/7/8/10	85.8 MB	2018-10-29	58b3d796d8cf96fb8580c62f46ab64d4
RStudio 1.1.463 - Mac OS X 10.6+ (64-bit)	74.5 MB	2018-10-29	a79032ba4d7daaa86a8da01948278d94
RStudio 1.1.463 - Ubuntu 12.04-15.10/Debian 8 (32-bit)	89.3 MB	2018-10-29	8a6755fa9fae2bafce289df3358aaf63
RStudio 1.1.463 - Ubuntu 12.04-15.10/Debian 8 (64-bit)	97.4 MB	2018-10-29	bc50d6bd34926c1cc3ae4a209d67d649
RStudio 1.1.463 - Ubuntu 16.04+/Debian 9+ (64-bit)	65 MB	2018-10-29	cfd659db18619cc78d1592fefaa7c753
RStudio 1.1.463 - Fedora 19+/RedHat 7+/openSUSE 13.1+ (32-bit)	88.1 MB	2018-10-29	742f0bad60dfeaa3281576e14ad6699e
RStudio 1.1.463 - Fedora 19+/RedHat 7+/openSUSE 13.1+ (64-bit)	90.6 MB	2018-10-29	c7303067a0ca99deea7e427b856952d1

Zip/Tarballs

Zip/tar archives	Size	Date	MD5
RStudio 1.1.463 - Windows Vista/7/8/10	122.9 MB	2018-10-29	1eb1d7758bd4bf4bb68d4a7c3fe8d894
RStudio 1.1.463 - Ubuntu 12.04-15.10/Debian 8 (32-bit)	90 MB	2018-10-29	ef9242b621d36c30de9d86b808840b41
RStudio 1.1.463 - Ubuntu 12.04-15.10/Debian 8 (64-bit)	98.3 MB	2018-10-29	5944b3dd118cfba46f2a6c484d768324
RStudio 1.1.463 - Fedora 19+/RedHat 7+/openSUSE 13.1+ (32-bit)	88.8 MB	2018-10-29	6bee446eeb4cc0e32967845e1f7ffe2b
RStudio 1.1.463 - Fedora 19+/RedHat 7+/openSUSE 13.1+ (64-bit)	91.4 MB	2018-10-29	3f63725769b7b976fedb754eb2a19108



R Studio 실행시 처음 뜨는 화면





R Console**에서 실행**

- ◎ R은 기본적으로 Interactive mode
 - R Console 창에서

프롬프트 '>' 다음에 수식 및 명령어를 입력하고 Enter를 입력하면 명령어가 실행됨

• 결과는 그 다음줄에 출력됨

```
> 5+7
[1] 12
> sqrt(3)
[1] 1.732051
> sqrt(4)
[1] 2
> pi
[1] 3.141593
> |
```

○ 기존의 SPSS나 SAS에서 활용되던 일괄처리방식보다 현재의 복잡해진 데이터 구조를 분석하기에 더 용이함



R 예제데이터

- ◎ 변수에 데이터를 입력한다→ 변수에 데이터를 할당한다는 의미.
 - 객체: R의 기본요소 R에서 다뤄지는 모든 것이 객체 객체는 다양한 구조의 데이터 객체가 존재함

- ◎ 데이터 입력: 함수 c()
 - R에서 사용되는 모든 명령문은 내장된 함수 혹은 사용자 정의 함수

◎ 할당 시 사용하는 기호는 <- OR =



R Console**에서 실행**

◎ 예제 데이터

speed	dist
4	2
5	4
6	8
7	16
8	10
10	18
11	24
13	34
13	17
14	26

※ 실습문제

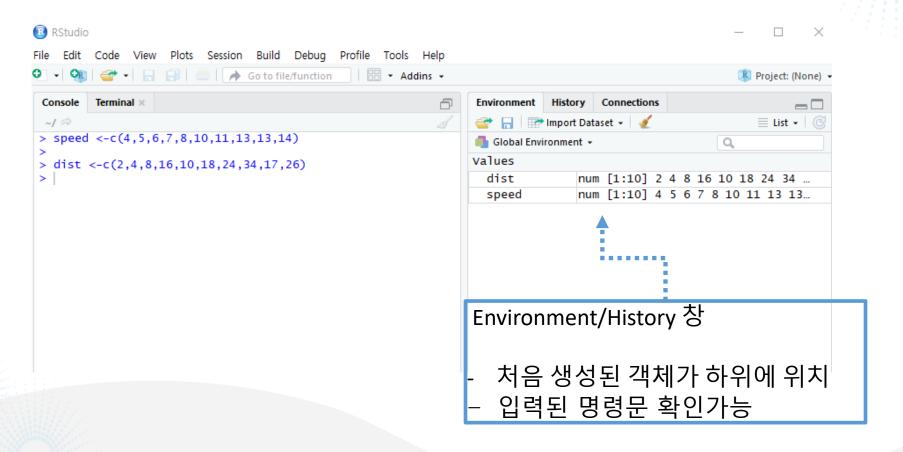
- 1. 두 변수 speed와 dist 생성 (자료입력)
- 2. 두 변수의 기술통계량 계산
- 3. 두 변수의 상관계수 계산 및 산점도 작성





📵 R **예제데이터**

- > Speed <-c(4,5,6,7,8,10,11,13,13,14)
- > dist = c(2,4,8,16,10,18,24,34,17,26)







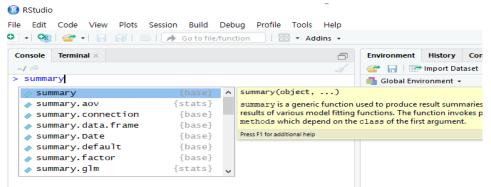
R 에제데이터-2번 실습문제

- ◎ 기술 통계량 계산에 관련된 R함수.
 - summary(): 최소, 최대, 평균, 중앙값, 1사분위수, 3사분위수
 - mean() : 평균
 - sd(): 표준편차
- ◎변수 speed를 함수 summary ()에 입력하고 실행
- ◎변수 dist를 함수 mean()과 sd()에 입력하고 실행

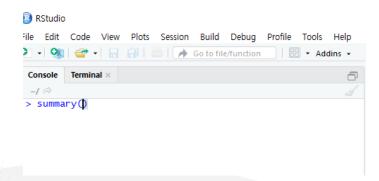




- 1) 함수 summary 입력
 - summary로 시작하는 함수 나열 (선택 가능) 및 도움말 표시

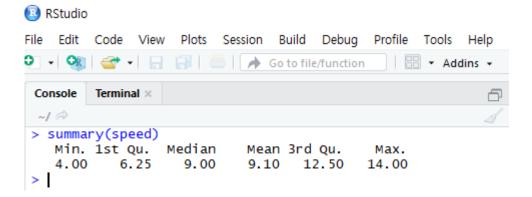


2) summary에 이어서 왼쪽 괄호 '(' 입력하면 오른쪽 괄호는 자동으로 생성





- R 예제데이터-2번 실습문제
 - 3) 괄호 안에 speed(객체)를 입력 후 실행



4) dist(객체)도 명령문을 입력하는 실습

```
> mean(dist)

> sd(dist)

> sd(dist)

> mean(dist)

[1] 15.9

> sd(dist)

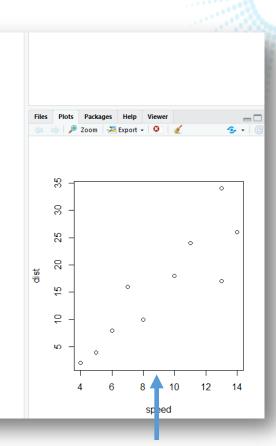
[1] 10.18114

> |
```



R 예제데이터-3번 실습문제

- 두 변수의 산점도: 함수 plot ()■ 함수 plot ()으로 산점도 작성> plot(speed, dist)



산점도



R 코딩시 주의사항

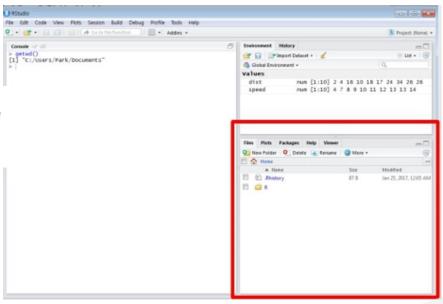
- 1. 영어 소,대문자를 구분하여 인식함
- 2. 명령문이 완성되지 않은 상태에서 Enter를 입력하면 프롬프트가 '>'에서 '+'로 바뀜
- 3. '#'입력 후 쓰는 문자는 주석으로 입력 (코딩에 영향을 미치지 않음)



🔞 R 작업 디렉토리 확인

- ◎ R의 작업공간은 작업 디렉토리(폴더)에 임시로 보관
- ◎ 현재의 작업 디렉토리를 확인하는 방법 1:- R Studio의 우측하단의 'File'창에서 확인(Console 창의 화살표 '새로고침 ' 버튼 후)
- Console Terminal × ~ 수 누르고 우측 하단을 확인 > summary(speed Min. 1st Qu. 4.00 6.25
- 현재의 작업 디렉토리를 확인하는 방법 2:- 함수 getwd () 실행
 - >getwd()

[1] "C:/Users/yspar/Documents"

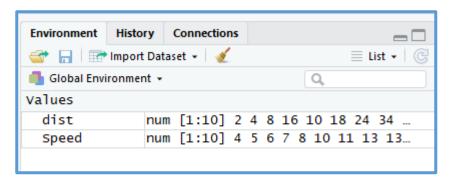




R 작업공간에 임시 저장된 객체 확

- ◎ 작업공간에 임시 저장된 객체 리스트 확인 시:
 - 1) 함수 Is() 실행

2) Environment 창에서 확인





📵 R 앞서 실행시킨 작업 확인

- 작업공간에 임시 저장된 앞서 실행시킨 명령문 확인 시:
 - 1) Console 창에서 ↑ 또는 ↓의 화살표 키 이용
 - 2) History 창에서 확인

```
Console Terminal
                                                                Environment History Connections
                                                                      To Console To Source 4 4
> Speed <-c(4,5,6,7,8,10,11,13,13,14)
> dist = c(2,4,8,16,10,18,24,34,17,26)
                                                               sqrt(3)
                                                               sqrt(4)
                                                               рi
                                                               Speed <-c(4,5,6,7,8,10,11,13,13,14)
                                                               dist = c(2,4,8,16,10,18,24,34,17,26)
[1] "dist" "Speed"
                                                               )
                                                               1s()
                                                               mean(Speed)
> mean(Speed)
                                                               sd(dist)
[1] 9.1
                                                               mean(dist)
> sd(dist)
                                                               sd(mean())
[1] 10.18114
> mean(dist)
                                                               sd(mean)
[1] 15.9
                                                               sd(Speed)
> sd(mean())
                                                               corr(speed, mean)
Error in mean.default(): argument "x" is missing, with no
                                                               cor(speed, dist)
default
                                                               cor(Speed, dist)
> sd(mean)
                                                               plot(Speed, dist)
Error in as.double(x) :
 cannot coerce type 'closure' to vector of type 'double'
[1] 3.60401
> corr(speed, mean)
Error in corr(speed, mean) : could not find function "corr"
> cor(speed, dist)
```

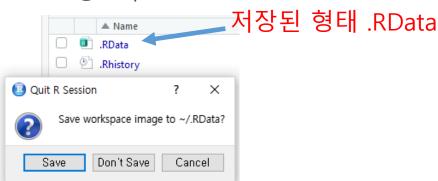


📵 R **작업 저장**

- R 작업 후 생성된 객체를 작업 디렉토리에 저장(형태: .R Data)
 - 1) 함수 save.image() 실행
 - 2) R 종료하는 방법:
 - 함수 q()로 종료 시



• 메뉴 File > Quit Session 으로 종료시



• R에서 입력한 명령문은 파일. Rhistory로 저장되는 것이 디폴트



📵 R **작업 저장**

- ◎ R 디폴트 작업 디렉토리의 변경
 - 디폴트 작업 디렉토리: >getwd() [1] "C:/Users/yspar/Documents"
 - 작업 디렉토리 변경
 - 1) 함수 setwd ("~/가고 싶은 폴더") 실행 (~는 디폴트 디렉토리)

```
      Console
      Terminal ×

      ~/카카오톡 받은 파일/ ๗

      > setwd("~/카카오톡 받은 파일")

      > |
```

- 2) 메뉴 Session > Set Working directory > Choose directory
- 3) Files 창 메뉴 More > Set as working directory
- 초보단계에서는 변경할 필요가 없음



📵 R **작업 저장**

- ◎ R 디폴트 작업 디렉토리의 변경
 - 디폴트 작업 디렉토리: >getwd() [1] "C:/Users/yspar/Documents"
 - 작업 디렉토리 변경
 - 1) 함수 setwd ("~/가고 싶은 폴더") 실행 (~는 디폴트 디렉토리)

```
      Console
      Terminal ×

      ~/카카오톡 받은 파일/ ๗

      > setwd("~/카카오톡 받은 파일")

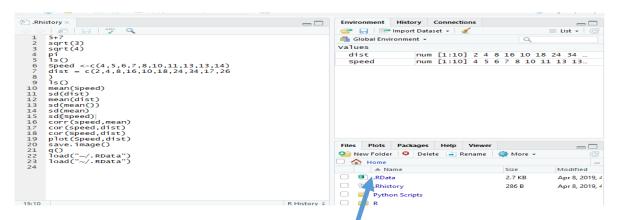
      > |
```

- 2) 메뉴 Session > Set Working directory > Choose directory
- 3) Files 창 메뉴 More > Set as working directory
- 초보단계에서는 변경할 필요가 없음



🔞 R <mark>파일로 저장된 작업 불러오기</mark>

◎ 디폴트 작업 디렉토리에 저장되면 : .Rhistory 실행시 코딩이 출력됨.



- 작업공간의 저장: 실제 상황에서는 사용하지 않는 것이 바람직
- 현재 저장된 작업공간<mark>은 제거하기</mark>
- R종료 시 저장 여부를 묻는 과정 생략
 - 1) Tools > Global options...
 - 2) 'Save workspace to .RData on exit'을 [Never]로 선택



R 의 경로표시의 특이사항

◎ Windows 에서의 경로

C:\Users\Park\Documents

또는 C:₩Users₩Park₩Documents

◎ R 에서의 경로표시

C:/Users/Park/Documents

또는 C:₩₩Users₩₩Park₩₩Documents





주요 이력

- 現) ㈜RTMC 전략기획실장
- 前) ㈜B사 웹로그분석 및 DP사업 完
- 前) ㈜H금속사 회계팀 선물환 및 자금관리
- 前) ㈜B건설사 회계팀 주석 공시
- 前) K문고 CRM VIP 군집전략 CRM프로젝트 보조연구원
- 前) L백화점 CRM Alert 전략 CRM프로젝트 보조연구원

BSL(스위스 로잔 비즈니스 스쿨) MBA ASSIST 빅데이터경영통계 MBA

국가공인 ADSP(빅데이터 준전문가)

- 現) 코리아IT아카데미 빅데이터 R 강사
- 現) 코리아IT아카데미 빅데이터 기초 파이썬 강사
- 現) 코리아IT아카데미 빅데이터 기초 ML 강사
- 現) 코리아IT아카데미 빅데이터 기초통계 전담강사
- 現) 코리아IT아카데미 빅데이터 취업 강사

"자료는 대가이신 박동련 교수님께 도움을 받았음을 밝힙니다."

[박영식] <u>완성에 이르기까지</u>